UFPEL

ENIAC 2026

Balanceando o MINA-BR com um LLM uncensored

Aumento de dados para detectar discurso de ódio misógino em português brasileiro

Andrew B. Campos · Ulisses B. Corrêa · Larissa A. de Freitas · PPGC — Universidade Federal de Pelotas

Aviso: esta apresentação contém exemplos de linguagem ofensiva.

MOTIVAÇÃO

Pouco dado de ódio, e os LLMs se recusam a gerar

- Discurso de ódio ataca pessoas por atributos como raça, religião ou **gênero** — e cresce com as plataformas.
- Em português brasileiro, os corpora anotados são **escassos e muito desbalanceados**.
- LLMs comerciais (GPT-4, Claude) passam por alinhamento de segurança e **recusam** produzir conteúdo de ódio, mesmo em pesquisa.

PERGUNTA

Um LLM com a recusa removida pode gerar exemplos **úteis** da classe minoritária e melhorar um classificador?

DATASET

MINA-BR: misoginia com classes desbalanceadas

Comentários no MINA-BR

6.002

Coletados do Twitter e do YouTube, com foco em misoginia.

Anotadores independentes

3

Subconjunto MINA-BR-rotulada, com rótulo “ódio” vs. “não ódio”.

Não ódio : ódio

≈ 9:1

A classe de interesse é a minoritária.

Ética: coleta e anonimização aprovadas pelo sistema CEP/Conep (CAAE 44357921.4.0000.5404).

MODELO GERADOR

O que é um modelo abliterated?

- Arditi et al. (2024): a recusa é mediada por **uma única direção** no residual stream.
- A direção é estimada por diferença de médias e removida por **ortogonalização dos pesos**.
- O modelo deixa de recusar, mas mantém as capacidades em quatro benchmarks de linguagem.
- Servido localmente com **vLLM**.

MODELO USADO

huihui-ai/Qwen2.5-14B-Instruct-abliterated

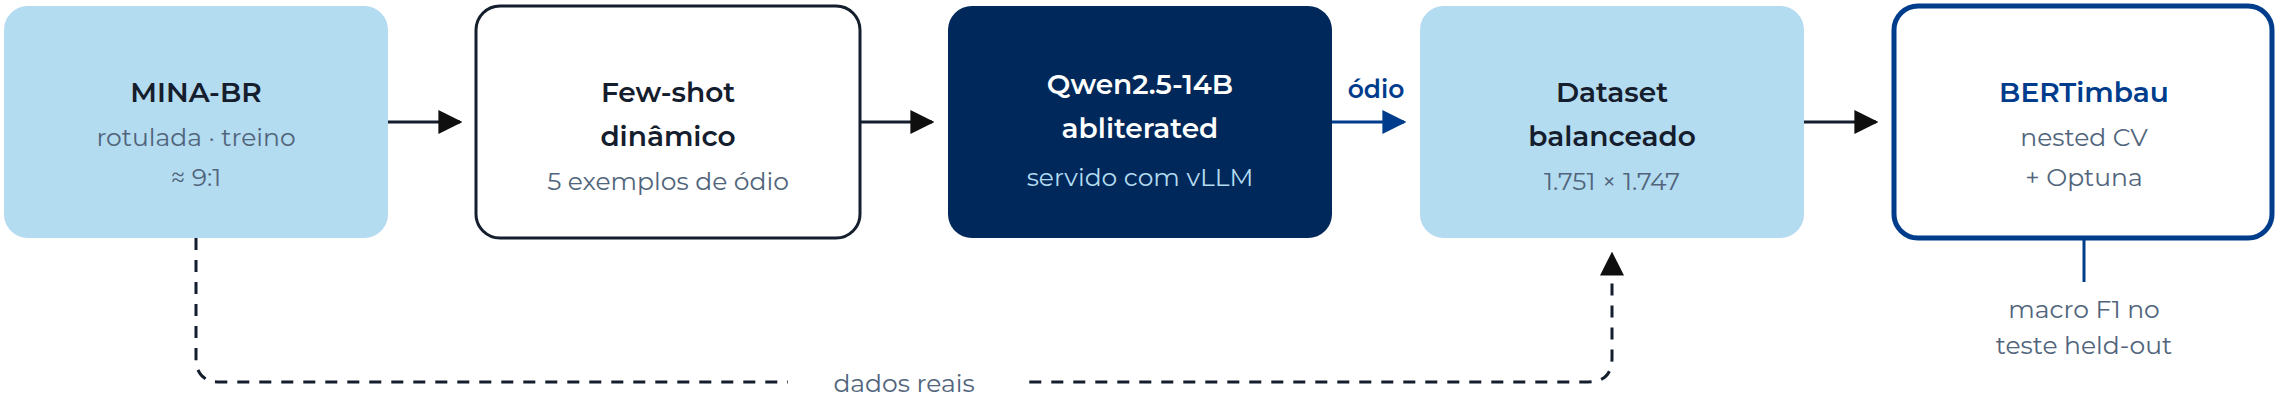
Qwen2.5-14B-Instruct com a direção de recusa removida.

MÉTODO

Pipeline: gerar ódio sintético e balancear

GERAÇÃO DE DADOS

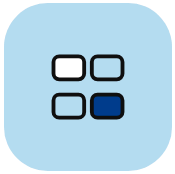
CLASSIFICAÇÃO



GERAÇÃO

Few-shot dinâmico: um prompt novo a cada chamada

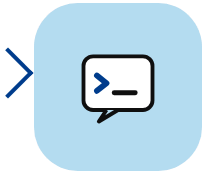
Etapa 01



Amostragem

5 comentários de ódio reais sorteados do treino a cada chamada, evitando viés de ordem.

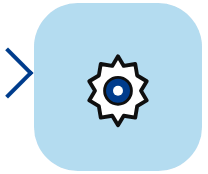
Etapa 02



Prompt

Exemplos injetados como referência de tom e grafia reais da internet.

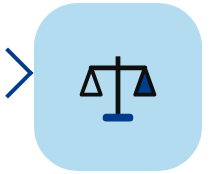
Etapa 03



Inferência

temperature 0,7 · top-p 0,8
top-k 20 · presence penalty 1,0

Etapa 04



Balanceamento

1.751 instâncias “não ódio” e 1.747 “ódio” no dataset final.

AVALIAÇÃO

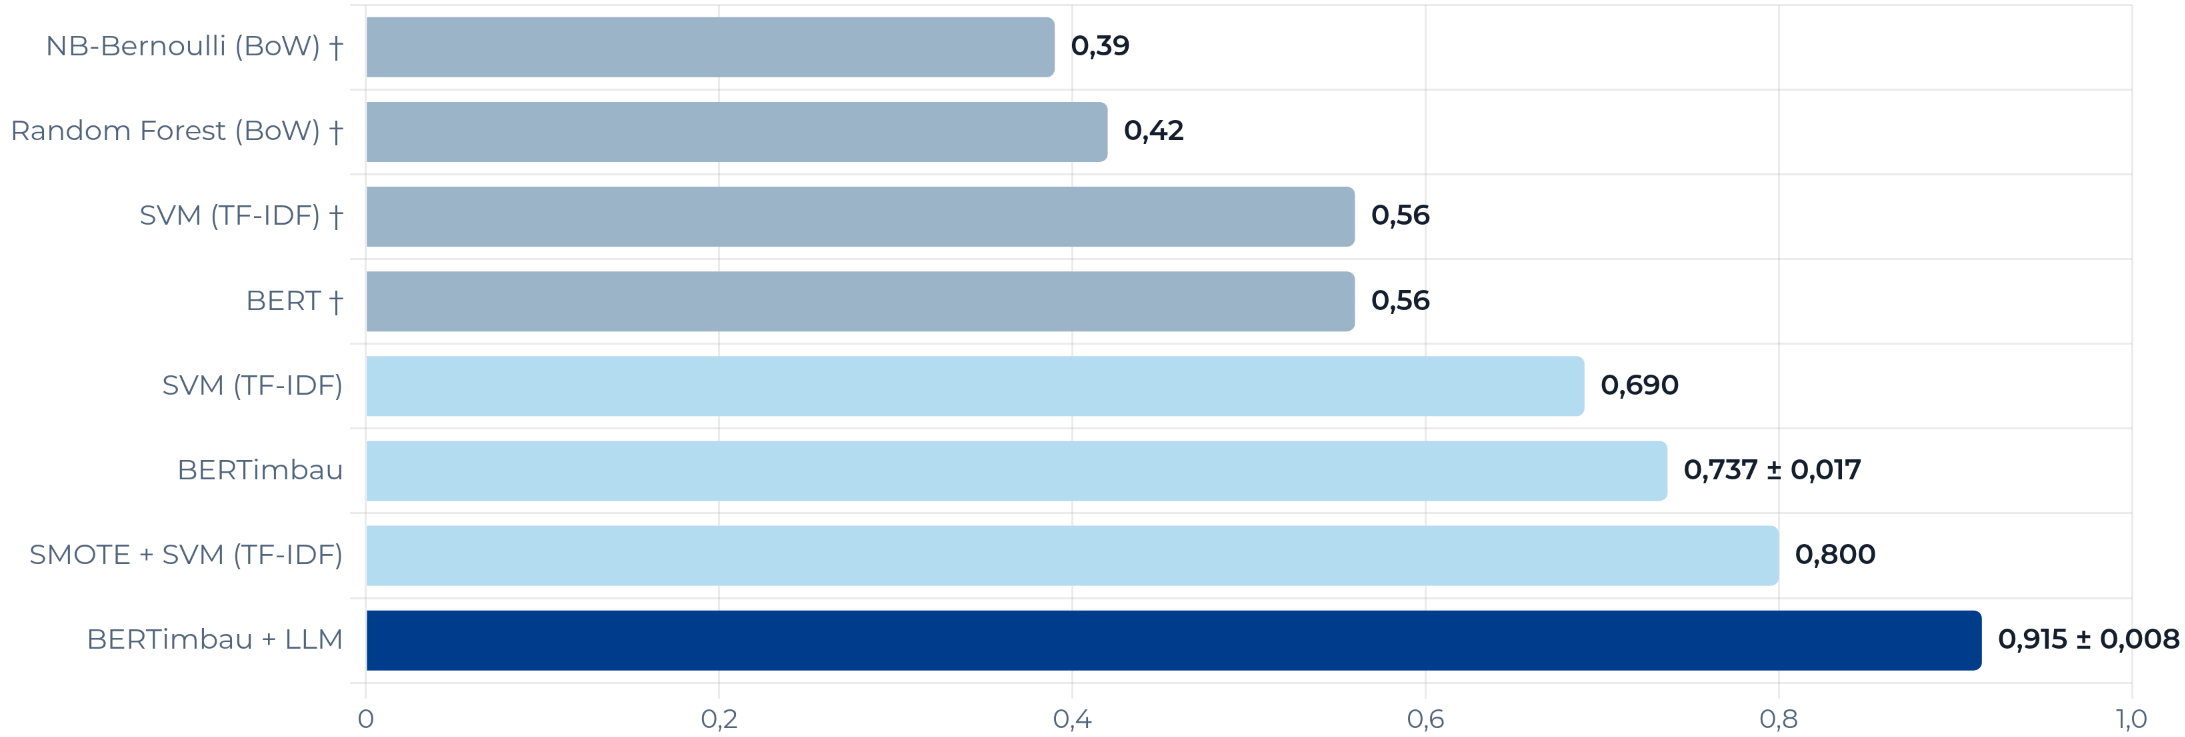
Cada pipeline na sua melhor configuração

Pipeline	Representação	Balanceamento	Seleção de hiperparâmetros
SVM	TF-IDF	—	Grid search, 5-fold estratificado
SMOTE + SVM	TF-IDF	SMOTE no espaço vetorial	Grid search, 5-fold estratificado
BERTimbau	Contextual	—	Nested CV + Optuna
BERTimbau + LLM	Contextual	**Texto gerado pelo LLM**	Nested CV + Optuna

BERTimbau Base: 12 camadas, 768 dim., até 512 tokens, cabeça linear sobre [CLS], AdamW. Nested CV separa a escolha de hiperparâmetros da avaliação final.

RESULTADOS

Macro F1 no MINA-BR: 0,915 com dados do LLM



† Baselines publicados por Plath et al. (2022). Em azul-claro, nossos baselines. BERTimbau: média ± desvio nos folds externos do nested CV.

RESULTADOS

Ganho grande e estável entre as partições

vs. BERTimbau sem aumento

+17,8 p.p.

Macro F1 de 0,737 → 0,915.

vs. melhor baseline publicado

+35,5 p.p.

Macro F1 de 0,560 → 0,915.

F1 da classe ódio

0,916

Contra 0,583 sem aumento e 0,671 com SMOTE + SVM.

Estabilidade: desvio-padrão do macro F1 cai de ± 0,017 para ± 0,008 nos folds externos — menos da metade.

ANÁLISE

Não é só balancear: a qualidade do texto pesa

- No trabalho original, BERT empata com SVM em 0,560: representação contextual sozinha não vence o desbalanceamento.
- **SMOTE** interpola vetores TF-IDF e já leva o SVM de 0,690 para 0,800.
- O **LLM** gera exemplos em linguagem natural e o BERTimbau chega a 0,915.

LEITURA

Balancear ajuda, mas o maior ganho vem de **gerar texto realista** da classe minoritária.

O modelo generaliza, não copia os exemplos

Type-Token Ratio médio

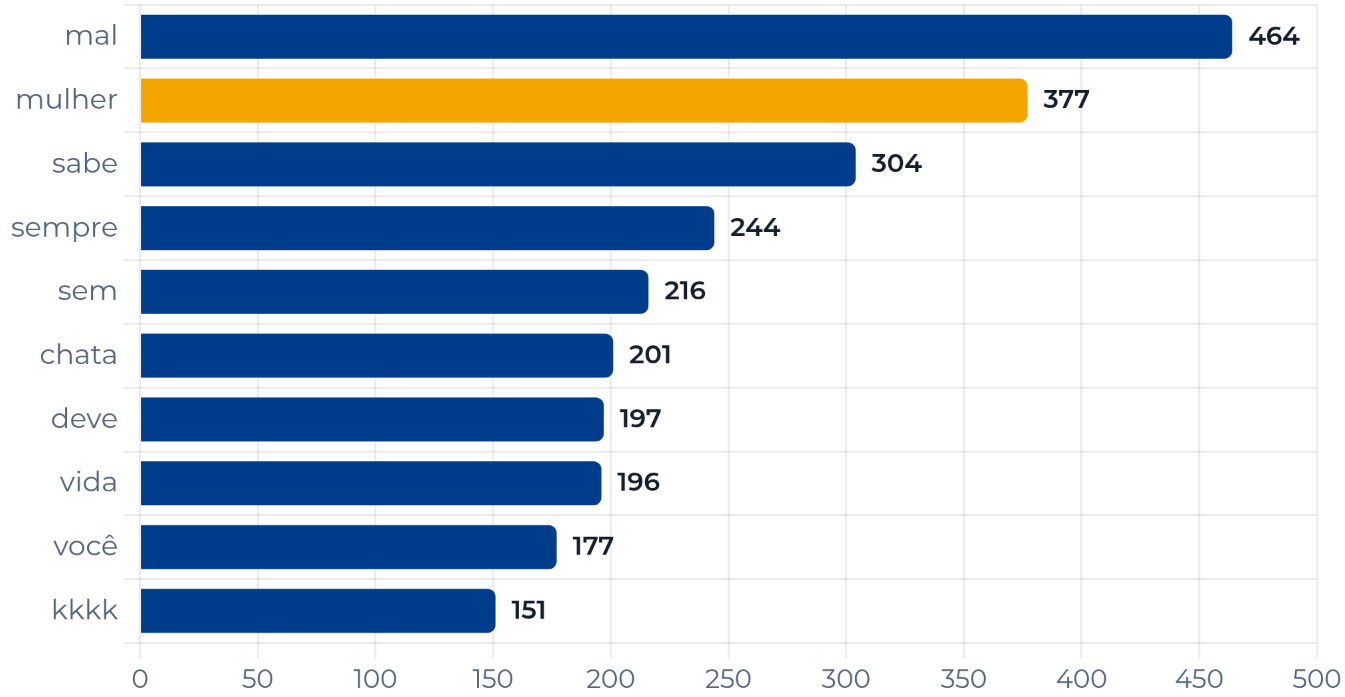
0,974

Alta diversidade lexical dentro de cada instância.

Jaccard com os exemplos do prompt

0,043

Sobreposição quase nula com o few-shot.



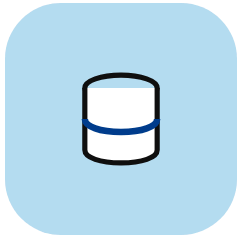
Top-10 palavras da classe ódio no dataset aumentado. “mulher” (laranja) também lidera a classe não ódio (331).

Uso duplo e limites do estudo



Uso responsável

A mesma capacidade pode gerar ódio em escala. Defendemos uso restrito à pesquisa, com salvaguardas, e não liberamos os dados gerados.



Um único dataset

A generalização para HateBR e ToLD-BR ainda está em aberto.



Sem avaliação humana

Falta comparar textos gerados e reais com anotadores humanos.

CONCLUSÕES

O que levamos deste trabalho

- Um LLM abliterated com few-shot dinâmico balanceou o MINA-BR com texto diverso e pouco copiado.
- BERTimbau com os dados aumentados atingiu **0,915 de macro F1**, +35,5 p.p. sobre o estado da arte publicado.
- A qualidade do texto gerado, e não só o balanceamento, explica o ganho.
- **Próximos passos:** outros corpora, avaliação humana, outras estratégias de prompt e outros modelos abliterated.

CÓDIGO

github.com/AndrewwBC/ENIAC_HS

Os dados sintéticos não são distribuídos.

UFPEL

Obrigado!

Andrew B. Campos · abdcampos@inf.ufpel.edu.br
Ulisses B. Corrêa · ulisses@inf.ufpel.edu.br · Larissa A. de Freitas · larissa@inf.ufpel.edu.br
Financiado em parte pela CAPES — Código de Financiamento 001